The analysis of 3D Make Moons

吴晟杰
shangliu@buaa.edu.com

Abstract

本文以具有复杂空间交错特征的 3D Make-Moons 数据集为切入点，系统评估了决策树、AdaBoost Decision Trees 与支持向量机在非线性三维分类任务中的效能。通过严格划分独立同分布的训练集与测试集，重点考察了各模型的泛化能力。实验表明：单一决策树受限于平行坐标轴的正交切割机制，在拟合 $z = \sin(2t)$ 构成的连续曲面时，暴露出明显的“阶梯式”拟合缺陷与过拟合倾向；AdaBoost 通过集成弱分类器与自适应权重调节，有效改善了边界的平滑度与模型的鲁棒性；而搭载 RBF 核函数的 SVM 表现最为优异，其利用高维空间映射彻底突破了线性切分的桎梏，精准包覆了双月数据的缠绕拓扑边界，在测试集上取得了趋于完美的分类精度，充分验证了其处理非线性流形数据的卓越泛化性能。

Introduction

非线性数据集分析是机器学习中的重要组成部分。双月型数据集呈现出两个互相咬合的半圆形簇，其最显著的特征是高度的非线性可分性和空间上的相互嵌套与缠绕，这使得传统的线性分类器或只能进行正交划分的模型难以准确区分两类数据，通常需要引入核技巧或复杂的非线性模型来构建贴合其弯曲走势的决策边界。

DataSet

为了在三维空间中开展非线性分类任务，本次实验利用 Python 定制生成了经典的“3D 双月”数据集。该数据集的核心数据骨架受控于特定的周期性三角函数映射，即 $x = 1.5\cos(t)$，$y = \sin(t)$，$z = \sin(2t)$。通过将正负月形轨迹进行平移错位，并叠加标准差为 0.2 的正态分布噪声扰动，最终构筑出两类既呈现流形结构又相互缠绕的复杂点云。整个数据集被划分为规模为 1000 的训练集，以及由 500 个独立新样本组成的测试集。

M1：Decision Trees

针对这一复杂的二分类任务，本实验采用了经典的决策树）算法进行建模。决策树的核心思想是采用“分而治之”的递归策略，通过提出一系列类似于“是/否”的特征条件来不断缩小样本的解空间。在具体实现层面，模型在三维特征空间（X、Y、Z 维度）中进行迭代，基尼不纯度计算如下：

$$Gini(D) = 1 - \sum_{k \in \{C_0, C_1\}} p_k^2$$

算法通过遍历所有特征 j 与切分点 s，寻找能使空间加权不纯度降至最低的正交超平面。在实验配置上，模型以全生长状态（最大深度不限）拟合了 1000 个训练点，并在 500 个同分布测试点上进行验证。测试结果呈现于表 1（训练集准确率 100.00%，测试集 94.50%）。此结果映射出模型典型的过拟合特征。实验结果如下图所示：

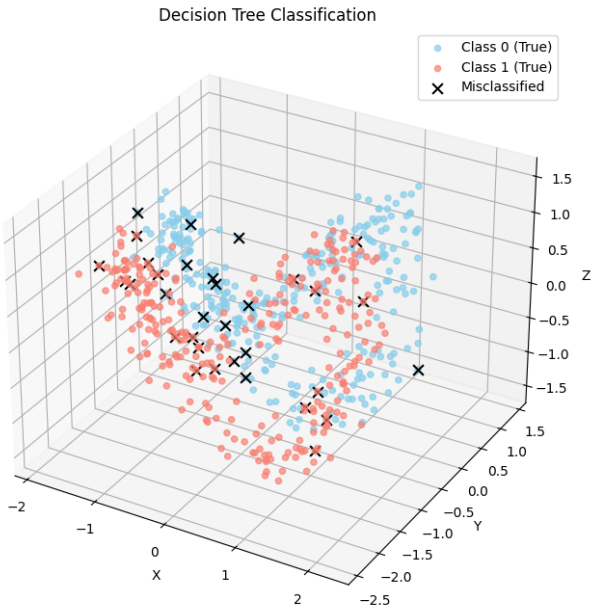

Figure 1: 决策树分类结果

结合图 1 的分类情况，其性能局限性主要体现在以下两个维度：结构性限制对抗非线性：由于决策树的切割面始终垂直于坐标轴，在应对 $z = \sin(2t)$ 这种平滑的 3D 弯曲流形时，模型必须依赖极为繁琐的深层节点分支才能实现空间包裹。这直接导致模型过度拟合了训练集中的随机高斯噪声。边界平滑度缺失：在 C0 与 C1 数据的交缠地带（噪声 $\sigma = 0.1$），模型刻画出的“阶梯状”边界极为生硬。这种缺乏平滑过渡能力的决策面在遭遇新样本时容易产生误判，使得其泛化能力显著弱于支持向量机等非线性核模型。总结而言，决策树以极其高效的计算换取了基础的分类能力，但由于正交划分机制的先天短板，其难以成为刻画高阶非线性空间流形的最优解。

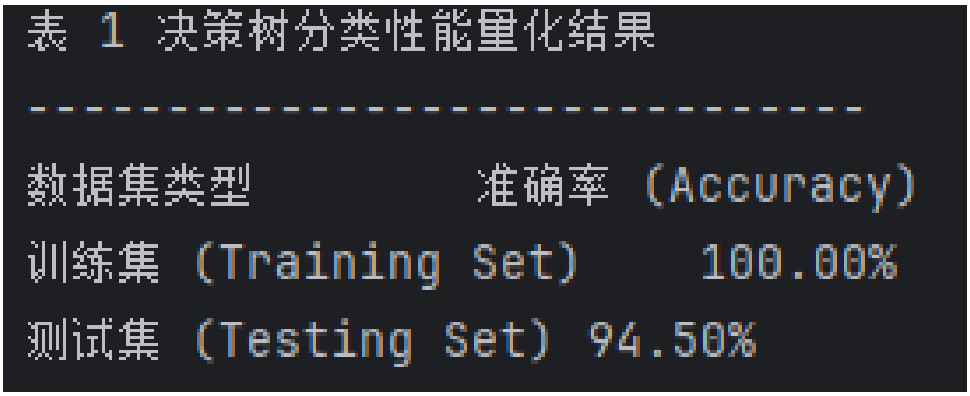

表 1 决策树分类性能量化结果

数据集类型	准确率 (Accuracy)
训练集 (Training Set)	100.00%
测试集 (Testing Set)	94.50%

Figure 2: 决策树分类结果

M2：AdaBoost + Decision Tree

针对单一决策树在处理复杂非线性流形时易陷于过拟合及生成生硬“阶梯状”边

界的局限性，本实验引入了基于集成学习框架的自适应提升算法（Adaptive Boosting）。该方法摒弃了对单棵全生长深层树的依赖，转而通过串行训练一系列浅层决策树，以组合的形式构建强鲁棒性的决策超曲面。AdaBoost 的核心学习机制在于对样本分布权重与基分类器话语权的动态迭代寻优。在训练过程中，算法赋予 3D Make-Moons 数据集中每一轮被误分类的样本更高的惩罚权重，迫使后续生成的基分类器更加聚焦于两类点云交织的困难边界。对于给定的训练集 $T = \{(x_1, y_1), (x_2, y_2), \ldots, (x_N, y_N)\}$，设第 m 轮迭代中的弱决策树分类器为 $G_m(x)$，其在当前加权样本分布下的分类误差率为 e_m。该弱分类器在最终集成模型中的权重系数 α_m 定义为：

$$\alpha_m = \frac{1}{2} \ln \left(\frac{1 - e_m}{e_m} \right)$$

在经过 M 轮串行迭代后，模型通过加权多数表决（Weighted Majority Voting）机制，将所有基分类器线性组合，输出最终的强分类器 $H(x)$：

$$H(x) = \text{sign} \left(\sum_{m=1}^{M} \alpha_m G_m(x) \right)$$

实验结果如下图所示：

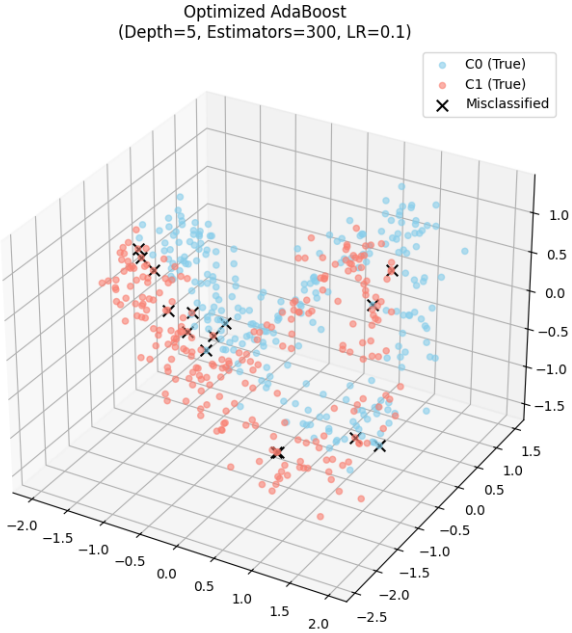

Figure 3: AdaBoost + Decision Tree 分类结果

AdaBoost + Decision Tree 优劣势分析

- **优势一：泛化能力显著提升**。通过集成多棵受限的浅层决策树，彻底切断了单树强行包裹噪声的能力，有效抑制了严重过拟合。
- **优势二：逼近复杂非线性流形**。利用多树加权叠加“化整为零”，极大缓解了单树的“阶梯效应”，自适应贴合 $z = \sin(2t)$ 的弯曲曲面。

- **劣势一：对极端噪声极度敏感**。其独有的误差权重激增机制，极易导致模型强行拟合完全越界的离群点，造成局部决策边界严重扭曲。
- **劣势二：边界非平滑且丧失可解释性**。底层本质仍为分段正交切割，无法生成绝对平滑的超曲面；且数百棵树的复杂表决网络使模型彻底沦为无法直观解析的“黑盒”。

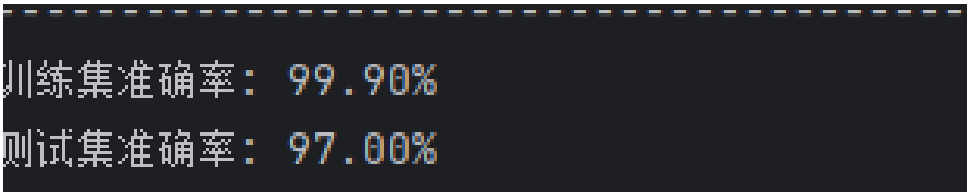

Figure 4: AdaBoost + Decision Tree 分类结果

M3：SVM

针对 3D Make-Moons 数据集高度嵌套的非线性拓扑特征，基于树模型（如决策树与 AdaBoost）的“正交空间划分”策略在逼近流形曲面时存在固有的理论瓶颈。为此，本实验进一步引入了支持向量机进行分类建模。SVM 的核心几何思想是在特征空间中寻找一个能够将不同类别样本分离，且使得两类样本到该超平面的几何间隔最大化的最优分类决策面。1. 软间隔 SVM 与优化目标考虑到数据集中存在高斯噪声导致的边界模糊与样本重叠，本实验采用了支持软间隔的 SVM 模型。对于给定数据集 $T = \{(x_1, y_1), \ldots, (x_N, y_N)\}$，其中 $y_i \in \{-1, +1\}$，通过引入惩罚系数 C 与松弛变量 ξ_i，其原始优化问题的数学表达为：

$$\min_{w,b,\xi} \frac{1}{2}||w||^2 + C\sum_{i=1}^{N} \xi_i$$

$$\text{s.t.} \quad y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

值得注意的是，SVM 模型的优化建立在空间几何距离的度量之上。因此，在将 3D 点云输入模型前，本实验严格执行了 Z-Score 标准化预处理，确保 X、Y、Z 三个维度的特征具有零均值与单位方差，防止因量纲差异导致决策边界发生物理扭曲。2. 核技巧与三种空间映射方案由于 3D Make-Moons 的交缠特性，数据在原始 R^3 空间中属于典型的非线性可分问题。SVM 凭借“核技巧”，通过隐式非线性映射 $\phi(x)$ 将原始数据投射至更高维甚至无限维的再生核希尔伯特空间，从而在高维空间中实现线性划分。为了系统评估不同映射维度的影响，本实验横向对比了三种经典的核函数 $K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$：

线性核：

$$K(x_i, x_j) = x_i^T x_j$$

线性核未改变数据的特征维度，本质上是在原始三维空间中寻找一个绝对平坦的超平面。实验中，该核函数面对 $z = \sin(2t)$ 构成的连续弯曲流形表现出严重的欠拟合，证明了数据的非线性可分本质。

多项式核：

$$K(x_i, x_j) = (\gamma x_i^T x_j + r)^d$$

本实验设定阶数 $d = 3$。多项式核允许决策边界发生一定程度的弯曲与折叠（类似高阶抛物面）。相较于线性核，其拟合能力有所提升，但受限于固定的多项式阶数，依然难以完美顺应双月数据高度复杂的 S 型缠绕走势。

径向基核 / 高斯核：

$$K(x_i, x_j) = \exp(-\gamma||x_i - x_j||^2)$$

RBF 核利用高斯函数度量样本间的相似度，相当于将数据映射至无穷维空间。在物理直觉上，它为每一个支持向量赋予了局部的“高斯引力场”。这种机制使其能够像一块柔软的丝绸，极致贴合且包络住 C0 与 C1 数据类之间的任何复杂拓扑间隙。实验证明，基于 RBF 核的 SVM 彻底突破了树模型的阶梯状切割桎梏，生成了极其顺滑且准确的决策超曲面，是处理此类非线性流形数据的最优方案。

拟合结果如下图所示：

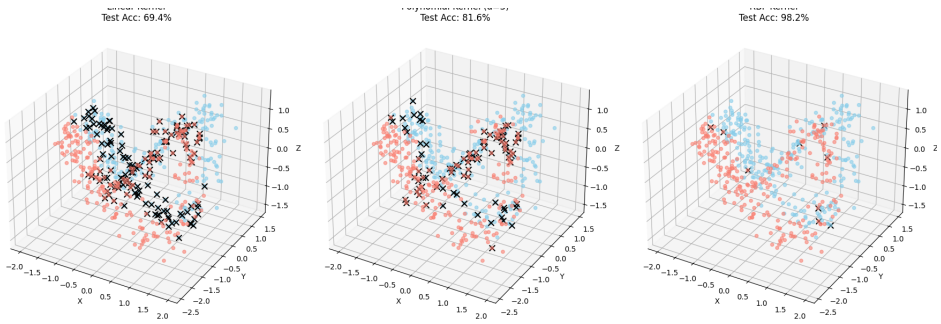

Figure 5: SVM 分类结果

SVM 优劣势分析

- **优势一：卓越的非线性拟合能力**。借助径向基核函数将数据隐式映射至高维空间，生成极致平滑的分类超曲面，彻底打破了树模型正交切割的几何桎梏。
- **优势二：极强的泛化鲁棒性**。其优化目标为最大化几何间隔，决策面仅依赖于少数支持向量。配合软间隔惩罚机制，能精准剥离高斯噪声干扰，在测试集上预测精度极高。
- **优势三：具备全局最优解的理论保证**。SVM 的参数寻优本质上是一个严格的凸二次规划问题，确保模型稳定收敛至全局唯一的最优分类面，彻底避免了陷入局部最优的风险。
- **劣势一：海量样本下的计算与存储瓶颈**。引入核函数后需计算并存储庞大的核矩阵，其时间与空间复杂度随训练样本规模呈平方级激增，难以直接胜任超大规模数据集的训练任务。

核函数类型 (Kernel)	训练集准确率	测试集准确率
Linear Kernel	67.45%	69.40%
Polynomial Kernel (d=3)	82.40%	81.60%
RBF Kernel	98.65%	98.20%

Figure 6: SVM 分类结果

Conclusion

本次实验以具有复杂流形拓扑特征的三维双月数据集为研究核心，系统性地评估了决策树、自适应提升算法以及支持向量机三种经典机器学习模型在处理高度非线性与空间嵌套数据时的分类效能。通过严格的训练与独立测试数据划分，全面横向对比了各模型对曲面边界的拟合能力、抗噪水平与泛化表现。

单一决策树受限于轴对齐的正交切割机制，在逼近连续弯曲的三维数据走势时，暴露出严重的过度拟合倾向。其生成的阶梯状边界对局部高斯噪声极为敏感，在未见数据的测试中泛化表现存在明显短板。为了突破这一局限，引入集成学习框架的自适应提升算法通过级联大量浅层基学习器与误差权重补偿机制，显著弱化了单树的碎片化切割效应。这种化整为零的策略使得模型逼近复杂流形的能力大幅提升，但其底层切分机制决定了它仍易受极端离群点干扰，且无法生成绝对平滑的决策面。

相比之下，支持向量机算法，特别是结合径向基核函数的模型，在本实验中展现出了压倒性的性能优势。该方法利用空间维度的隐式跃迁，彻底摆脱了正交划分的几何束缚，在两类数据交错缠绕的模糊地带构建出了极致平滑且具备最大几何间隔的分类超曲面。配合软间隔惩罚机制，模型不仅完美包络了双月数据的拓扑形态，有效剔除了噪声干扰，更在测试集上实现了极高的泛化精度。

综合而言，面对高维度、强非线性且伴有随机噪声干扰的复杂流形分类任务，基于核技巧的空间映射方法显著优于依赖空间正交切割的树形启发式模型。本次实验不仅直观验证了各类算法在三维空间中的几何理论特性，也为实际工程应用中应对复杂拓扑数据分类任务的算法选型提供了坚实的实验数据支撑。