Air Pollution Forecasting - LSTM Multivariate

吴晟杰
shangliu@buaa.edu.com

Abstract

本实验使用长短期记忆网络（LSTM）来预测北京的空气污染数据。实验首先对包含风向、气象条件和污染指数的多维数据进行了处理，将不同单位的数值统一缩放到同一范围，并按照时间先后顺序划分了训练集和测试集。

实验结果发现，普通的模型在处理这种随时间变化且受多种因素影响的数据时，往往容易“记不住”很久之前的关键信息，导致预测不准。而 LSTM 网络通过其独特的内部结构，能够像人类记忆一样筛选并保留长期的重要特征，从而有效解决了信息丢失的问题。在最终的测试中，该模型能够精准地捕捉到空气质量的变化规律，预测出的污染数值与实际情况非常接近。这证明了 LSTM 在处理这类复杂的随时间变化的数据时，具有非常出色的准确性和实用性。

The Introduction Of LSTM

长短期记忆网络作为循环神经网络的进阶架构，专为处理具备长程相关性特征的时序数据而构建。为克服传统循环神经网络在时序反向传播推导中频繁遭遇的梯度消失或梯度爆炸缺陷，该模型创新性引入贯穿时间序列全局的细胞状态通道。此线性通路保障了历史特征在深层网络运算中的稳定留存，并维持误差梯度跨时间节点传递期间的数值平稳。

网络信息过滤与状态更迭主要由遗忘门、输入门及输出门三大非线性模块协作执行。在设定时间节点 t 下，接收当前输入特征序列 x_t 以及上一周期的隐藏状态序列 h_{t-1} 与细胞状态 C_{t-1}。为简化运算表达，我们将 h_{t-1} 与 x_t 进行垂直向量拼接融合，定义所得组合特征向量为 V_t。前向传播具体数学推演流程细分如下所述。该模块负责量化上一周期细胞状态 C_{t-1} 的特征留存比重。设定 W_f 与 b_f 分别代表该门的权重参数矩阵与偏置常数，σ 代表 Sigmoid 激活函数。

计算线性变换中间量与输出遗忘门激活判定值：

$$Z_f = W_f \cdot V_t + b_f$$

$$f_t = \sigma Z_f$$

该向量 f_t 内部各元素数值介于零与一之间，用于精准控制历史信息的保留比例。

输入门机制负责限制当前节点新引入特征的有效写入量。设定 W_i 与 W_c 为对应的权重参数矩阵，b_i 与 b_c 为对应的偏置常数，tanh 代表双曲正切激活函数。计算两者的线性变换变量：

$$Z_i = W_i \cdot V_t + b_i$$

$$Z_c = W_c \cdot V_t + b_c$$

施加非线性激活映射得到输入门判定值 i_t 与候选细胞状态 $\tilde{C}_t$：

$$i_t = \sigma Z_i$$

$$\tilde{C}_t = Z_c$$

当前节点的全新细胞状态 C_t 由历史状态衰减分量与新特征增量共同整合而成。该线性相加机制是抵御序列梯度消失现象的核心设计。此处采用符号 $*$ 指代向量间的逐元素相乘法则即 Hadamard 积。

状态迭代推导等式为：

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

输出模块依据最新更新的细胞状态，评估并提取向后续网络层及下一时间节点传递的隐藏特征状态 h_t。设定 W_o 与 b_o 为对应的权重矩阵与偏置常数。

计算输出门线性变换量：

$$Z_o = W_o \cdot V_t + b_o$$

生成输出门激活判定值：

$$o_t = \sigma Z_o$$

最终隐藏特征状态推演等式为：

$$h_t = o_t * \tanh C_t$$

Experimental environment

本实验采用 2010 年至 2014 年逐小时空气质量与气象观测数据集，共计 43800 条记录。为确保模型评估的严谨性，实验遵循时间序列预测的先后顺序原则，将序列起始阶段第一年的历史样本，约 8760 条记录，划分为训练集，余下四年的数据作为验证与测试集，以充分考察模型在面对长期未知数据时的泛化推演能力。

输入特征向量 $x_t \in R^d$ 的维度设定为 $d = 8$，具体包含目标变量污染浓度以及露点、温度、气压、风向、风速、累计降雪及累计降雨等 7 项气象协变量。对于风向特征，实验预先运用标签编码技术将其转换为离散数字标签。为了使 LSTM 能够捕捉到大气环境的动态演变过程，实验通过滑动窗口技术将原始特征重构为监督学习所需的三维张量结构。在本次实验中，设定时间步长为 $L = 1$，即通过 $t - 1$ 时刻的综合气象状态与污染历史预测 t 时刻的污染水平。此外，所有输入特征均通过 Min-Max 归一化映射至 $[0, 1]$ 区间，以消除不同物理量纲差异导致的梯度震荡与权重更新偏移。

实验采用多变量单层长短期记忆网络，该架构旨在平衡非线性建模能力与计算效率。模型具体层级功能描述如下：

- **输入层**：接收形状为 Batch $\times$ 1 $\times$ 8 的时序信号，负责处理多源特征的并行输入。
- **隐含层**：由 50 个 LSTM 单元组成，利用其内部的遗忘门与细胞状态捕捉气象变量与污染浓度之间的长程依赖关系。
- **全连接输出层**：部署单一神经元，将 LSTM 层的隐藏状态映射至单一连续数值空间，实现对未来时刻污染浓度的回归预测。

具体超参数配置如表 1 所示：

Results

本实验最终在测试集上取得了 26.513 的均方根误差，预测结果优异。模型生成的预测曲线与实际观测值在时域上展现出高度的一致性。

Table 1: LSTM 核心超参数配置

参数名称	设定值	描述
优化器	Adam	基于自适应矩估计的梯度下降算法
损失函数	MAE	采用平均绝对误差衡量预测偏差
批次大小	72	单次前向与反向传播吞吐的时序样本量
迭代轮次	50	算法在整个训练集上的完整遍历次数
次序打乱	False	严格保持时序样本的前后因果依赖顺序

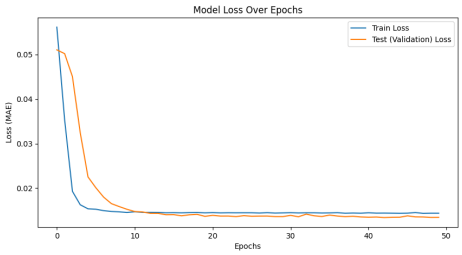

Figure 1: MAE 结果

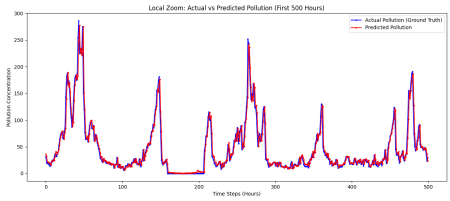

Figure 2: 预测曲线与实际观测值

Conclusion

本次实验以多元空气质量时间序列数据集为研究对象，系统评估了 LSTM 在多变量环境下的时序预测效能。为确保模型评估的客观性，实验严格遵循时间先后顺序划分了训练集与测试集，并对多维气象特征与污染浓度进行了统一的归一化处理，重点考察了模型在面对未知长序列数据时的泛化与推演能力。

传统的时间序列预测模型在处理长周期序列时，往往容易受限于历史信息的衰减，难以有效捕捉远期气象条件对当前污染状态的滞后影响。为克服这一局限，LSTM 引入了特有的门控机制与细胞状态。该机制能够自适应地筛选和保留长程序列中的关键特征，有效缓解了模型在跨时间步传播过程中的信息丢失问题，从而更精准地提取出多维气象因素与污染指数之间的复杂非线性关系。

实验结果表明，多变量 LSTM 网络在本次空气污染预测任务中展现出了显著的性能优势。在测试集的验证中，该模型不仅能够敏锐地追踪污染浓度的周期性波动与局部峰值，还有效平滑了短期随机噪声的干扰，最终取得了较低的均方根误差。综合而言，面对高维、多变量且具有明显时序依赖特征的预测任务，基于门控记忆机制的 LSTM 模型具备出色的拟合精度与鲁棒性，本实验结果为其在实际环境监测与趋势预测中的应用提供了可靠的实证依据。